

文章编号: 1003-0077(2025)09-0160-13

基于关系驱动多模态嵌入塑形的图像描述生成

周 练¹, 俞国瑞¹, 张玥杰¹, 冯 瑞¹, 张 涛², 张晓波³

(1. 复旦大学 计算与智能创新学院 上海市智能信息处理重点实验室 上海市智能视觉计算协同创新中心,

上海 200438; 2. 上海财经大学 信息管理与工程学院, 上海 200433;

3. 复旦大学附属儿科医院, 上海 201102)

摘 要: 记忆遗忘、错误积累和上下文依赖是基于序列的图像描述生成任务目前面临的主要挑战, 为减轻其影响并考虑语义和视觉嵌入之间的上下文依赖性, 该文针对图像描述生成提出一种基于关系驱动的多模态嵌入塑形方法。该方法聚焦于正则化关系三元组(主语、谓语和宾语)中涉及的多模态嵌入空间结构, 对每种模态的关系创建正三元组和负三元组。针对正三元组, 其宾语和所有主语、谓语的加和之间距离应尽可能小, 而负三元组的这种距离应尽可能大。基于这两个距离, 通过设计一个三重损失来实现正则化, 该三重损失随后通过多任务学习与图像描述生成模型的损失相结合。基于所提出的关系驱动多模态嵌入塑形方法, 关系的语义和视觉嵌入之间联系得到显著加强。在 Flickr30k 和 MSCOCO 数据集上的实验结果表明, 所提出的方法针对图像描述生成具有良好的性能改进。

关键词: 关系驱动; 多模态嵌入塑形; 图像描述生成

中图分类号: TP391

文献标识码: A

Relation-Driven Multimodal Embedding Shaping for Image Captioning

ZHOU Lian¹, YU Guorui¹, ZHANG Yuejie¹, FENG Rui¹, ZHANG Tao², ZHANG Xiaobo³

(1. College of Computer Science and Artificial Intelligence, Shanghai Key Laboratory of Intelligent Information Processing, Shanghai Collaborative Innovation Center of Intelligent Visual Computing, Fudan University, Shanghai 200438, China;

2. School of Information Management and Engineering, Shanghai University of Finance and Economics, Shanghai 200433, China;

3. Children's Hospital of Fudan University, Shanghai 201102, China)

Abstract: To deal with issues of forgetting, error accumulation and contextual dependencies in embeddings occurred in sequence-based image captioning task, this paper proposes a Relation-Driven Multimodal Embedding Shaping (RMES) method by regularizing the spatial structures of multimodal embeddings involved in a relation triplet (subject, action and object). For a relation of each modality, a positive and a negative embedding triplet are created. For the positive triplet, the distance between the object embedding and the summed subject and action embedding is expected to be as small as possible. In contrast, such a distance for the negative triplet should be as large as possible. Based on these two distances, regularization is achieved by designing a triplet loss which later integrates with the losses of the image captioning model via multitask learning. Experimental results on the benchmark Flickr30k and MSCOCO datasets show that the proposed RMES delivers promising performance improvement for image captioning.

Keywords: relation-driven; multimodal embedding shaping; image captioning

收稿日期: 2022-08-08 定稿日期: 2022-11-19

基金项目: 国家科技创新 2030—重大项目(2021ZD0114001, 2021ZD0114000); 国家自然科学基金(61976057, 62172101); 上海市科委“科技创新行动计划”人工智能科技支撑专项项目(21511101000); 上海市科委“科技创新行动计划”项目(22511106003)

0 引言

生成图像的文本描述通常涉及图像中的显著性物体及其交互关系,即一个图像文本描述通常是词语序列模式“物体-交互关系-物体-...-物体”的一个实例,如“a baseball player is swinging a bat at a ball”。目前,主流的基于序列学习的图像描述生成方法^[1-3]采用“编码器-解码器”结构将图像翻译成句子,其中序列解码器可看作是一个以图像作为条件的特殊语言模型^[4],而词嵌入(Word Embedding)^[5, 6-8]是该语言模型的学习产物。一个词语的嵌入是一个低维稠密的向量,该向量指示这个词语在语义向量空间中的位置。在本文方法中,词嵌入也被称为语义嵌入(Semantic Embedding)。此外,图像描述生成方法也会将图像的视觉信息编码成各种视觉嵌入(Visual Embedding)。图像的语义或视觉嵌入的相对空间位置关系是这些嵌入所对应词语或视觉信息之间所具有上下文依赖关系的具体反映。

虽然基于序列学习的图像描述生成方法已取得很大成功,但其中仍有一些问题亟待解决。第一,序列模型存在两个内在问题,即记忆遗忘和错误累积。这些问题会降低模型对图像内容的理解。例如,视觉注意力机制使用序列模型存在隐藏层状态来计算关于图像局部显著性区域的上下文视觉嵌入。然而,由于序列模型的上述两个问题,注意力模型计算得到的视觉嵌入可能不够准确,如错失显著性物体。第二,分散在句子中不同位置的词语在语义和句法上存在一定的依赖关系。但是,单层序列模型从左到右的词语生成方式难以很好地考虑这种复杂的词语间依赖,从而使词语所对应的嵌入难以很好地反映这些词语之间的上下文依赖关系。整体上,序列模型自身存在的问题容易导致质量欠佳的图像多模态嵌入,而低质量的嵌入是提升模型性能的障碍。目前,很多相关工作主要关注模型高层设计(如视觉和语义注意力机制^[2, 9]),以此来间接促进图像描述生成模型去学习更好的嵌入。这种对嵌入的改进方式是基于模型,而是否能够直接对低层嵌入施加一定的空间约束来提升图像多模态嵌入质量这个问题还未得到很好探索。

基于上述观察,本文对语义上有关联的一些词语所对应的语义和视觉嵌入施加一个空间约束,以

此来改善图像多模态嵌入的质量,进而提升图像描述生成模型的性能。因为图像文本描述包含大量的显著性物体及其交互关系,所以本文认为一个关系(Relation)中的词语在语义上具有紧密的依赖关系,而关系是指一个包含主语、动词和宾语的三元组。值得注意的是,动词可能包含多个词语,如“running on”。因此,本文将所提出的新方法称为关系驱动的图像多模态嵌入塑形(Shaping)。在本文方法中,对图像多模态嵌入的塑形最终体现为一个三元组损失函数项,则对于句子中的一个关系需构建基于该关系的语义或视觉嵌入三元组,包括正三元组(Positive Triplet)和负三元组(Negative Triplet),其中如何基于关系来构建负三元组是实现多模态嵌入塑形的关键。具体地,对于语义或者视觉模态,假设一个关系所对应的正、负嵌入三元组分别为 $(\mathbf{E}_s, \mathbf{E}_a, \mathbf{E}_o)$ 和 $(\mathbf{E}_s', \mathbf{E}_a, \mathbf{E}_o')$,其中下标 s、a 和 o 分别表示主语、动词和宾语,并且主语和宾语所对应的嵌入均为单位向量。值得注意的是,上面两个嵌入三元组共享相同的动词嵌入 $\mathbf{E}_a$ 。令 $dp = d((\mathbf{E}_s + \mathbf{E}_a) - \mathbf{E}_o)$, $dn = d((\mathbf{E}_s' + \mathbf{E}_a) - \mathbf{E}_o')$,其中, $d()$ 表示距离函数(如 L_2 距离),则本文方法要求 dp 尽可能小而 dn 尽可能大,且 dp 和 dn 要相差至少一个常数 $\lambda (>0)$ 。通过该空间约束,一个关系所对应的语义或视觉嵌入可被紧密联系在一起。因此,本文方法能够在嵌入层面建模词语所对应语义或视觉信息之间的上下文依赖关系。在模型优化方面,将图像描述生成和图像多模态嵌入塑形看作是两个任务。这两个任务共享相同的多模态嵌入并通过多任务学习(Multi-Task Learning)方式结合在一起,其中图像多模态嵌入之间的空间约束关系被当作常识(CommonSense)。本文方法是首个通过空间约束来优化图像多模态嵌入的方法。

本文研究工作的贡献主要涵盖如下三方面:①提出一种关系驱动的语义嵌入塑形方法来考虑词语之间的上下文依赖关系,从而帮助图像描述生成模型学习到具有更优空间结构的词嵌入;②提出一种关系驱动的视觉嵌入塑形方法来考虑视觉特征之间的上下文依赖关系,从而让图像描述生成模型能够更好地关注图像的显著性区域,其中如何基于视觉注意力映射来构建负视觉嵌入三元组是一个关键;③在 Flickr30k 和 MSCOCO 数据集上验证所提出方法的有效性,实验结果表明本文方法能够给图像描述生成模型带来性能提升,特别是在 Flickr30k 数据集上。

1 相关工作

1.1 基于上下文依赖关系建模的方法

在图像描述生成领域,上下文依赖建模是一个重要的研究主题。例如,Yao 等^[10]首先为一幅图像构建两种基于图的特征表示,即物体语义依赖图和空间位置关系图,然后利用图神经网络^[11]来实现这两种特征图上邻居信息的聚合,并最终得到更具判别性的图像多模态特征表示。Shi 等^[12]为一个图像文本描述构建语义场景图,并通过图神经网络来考虑不同词语间的上下文依赖关系,从而得到优化的图像语义特征表示。Liu 等^[13]提出一种视觉策略来建模图像中复杂的视觉上下文依赖关系,该策略可让解码器在某个时刻选择去关注历史视觉信息或者当前时刻的视觉信息。

此外,研究人员也尝试利用一些新型的解码器来实现图像描述的生成,其中最为典型的是 Transformer 模型^[14]。例如,Huang 等^[15]基于 Transformer 编码器的自注意力机制来优化图像的区域特征表示,从而考虑不同显著性物体之间的依赖关系。此外,Yu 等^[16]利用 Transformer 解码器来生成图像的文本描述,其中自注意力机制可考虑已生成词语之间的上下文依赖关系,但 Transformer 解码器无法将未来时刻的词语考虑进来,同时经过 Transformer 模型的处理,不同区域的视觉特征会混杂在一起,从而无法在视觉上明确区分不同的物体。因此,在目前基于 Transformer 的研究方向中,缺乏简单直观地挖掘词语和图像区域之间对齐关系的方法。然而,这正是本文所要解决的问题,希望探索图像中不同物体的视觉嵌入的空间联系,为此选用 LSTM 作为解码器。

上述相关工作通过基于模型的上下文依赖建模机制来实现图像多模态特征的优化。但是,这些相关工作并未尝试直接对图像多模态嵌入的空间结构进行优化。与此不同,本文方法通过对图像的多模态嵌入施加空间上的约束来考虑一个关系中词语之间的多模态上下文依赖关系,从而实现对图像多模态嵌入的优化。此外,通过将图像多模态嵌入之间的空间约束关系看作常识,本文方法能够从一个更加全局的角度来考虑图像多模态特征之间的上下文依赖关系,而不会受到序列解码器的影响。

1.2 嵌入翻译技术

文本数据中存在大量的实体及其关系。在知识图谱(Knowledge Graph, KG)^[17]领域,研究人员需要考虑如何在计算机中有效表示这些实体和关系、以及如何基于知识图谱来完成高效的关系推断等任务。在众多的知识图谱表示方法中,有一类方法尝试从词嵌入学习(Embedding Learning)的角度来解决上述问题。例如,Bordes 等^[5]提出 TransE 模型,该模型通过将实体之间的关系解释成实体低维嵌入之间的翻译(Translation)关系来学习实体和关系的空间向量表示。基于这个工作,目前已出现一些相关的改进方法,如 TransH^[6]、TransR^[7]和 TransD^[8]。

然而,上述相关工作只关注文本模态的数据,并且将学习实体和关系的向量表示看作一个单独的任务。虽然本文方法受到上述相关工作的启发,但关注的是一个关系中的词语以及基于这些词语的多模态嵌入塑形。此外,本文方法将图像多模态嵌入塑形和图像描述生成看作是两个任务,并将这两个任务进行结合。所以,本文方法在整体上是一个多任务学习的方法。

2 方法介绍

本节将对关系驱动的图像多模态嵌入塑形方法进行详细介绍。

2.1 方法概述

针对图像描述生成,为学习到更优的图像多模态嵌入,本文提出一种关系驱动的图像多模态嵌入塑形方法,如图 1 所示。该方法主要包含一个基于序列学习的图像描述生成模型和一个基于关系的图像多模态嵌入塑形机制。在本文方法中,图像多模态嵌入之间的空间约束关系被看作是一种常识,这种常识规定图像中的物体及其关系所对应的多模态嵌入在向量空间中应具有的空间位置关系。同时,上述常识可通过多任务学习的方式传递给图像描述生成模型。基于这些常识,图像描述生成模型所学习到的图像语义或视觉嵌入之间的上下文依赖关系可得到增强。




图1 关系驱动图像多模态嵌入塑形方法概览

2.2 图像描述生成模型

基于序列学习的图像描述生成方法^[2]通常包括一个图像编码器和一个具有视觉注意力模块的序列解码器。在本文方法中,输入图像 I 被表示成一个物体级别区域的集合,即 $R = \{r_1, \dots, r_n\}$, 其中 $n (\geq 1)$ 表示区域的数目。这些区域可通过基于物体检测的图像编码器生成(如 Faster R-CNN^[18])。相应地,这些区域可被编码成一个特征向量的集合,即 $V = \{v_1, \dots, v_n\}$, 其中, $v_i \in \mathbb{R}^{d_v}$, $1 \leq i \leq n$, d_v 表示特征维度。

在本文方法中,具有视觉注意力模块的 LSTM 模型被用作解码器。解码器的目标是基于图像的视觉特征 V 去生成对应的句子 $Y = (y_0, \dots, y_d, y_{d+1})$, 其中, d 表示句子的长度, y_0 和 y_{d+1} 分别表示开始符号和结束符号。句子中的每个词被表示成一个独热向量。词嵌入矩阵 $W_e \in \mathbb{R}^{d_e \times K}$ 被用来将一个独热向量映射成一个低维稠密向量,其中, K 表示词表的大小, d_e 表示词嵌入的维度。如式(1)所示。

$$x_t = W_e y_t, \quad 0 \leq t \leq d+1, d \geq 1 \quad (1)$$

解码器的状态更新方式如式(2)所示。

$$h_t, m_t = \text{LSTM}(x_{t-1}, o_{t-1}, h_{t-1}, m_{t-1}) \quad (2)$$

具体地,解码器在时刻 t 接收 $x_{t-1}, o_{t-1}, h_{t-1}$ 和 m_{t-1} 作为输入,并输出 h_t 和 m_t , 其中 o_{t-1}, h_{t-1} 和 m_{t-1} 分别表示输出层在时刻 $t-1$ 的上下文特征向量、解码器在时刻 t 的隐藏层状态和解码器在时刻 t 的记忆单元状态。在 h_t 被生成之后即可计算 o_t , 如式(3)~式(6)所示。

$$e_i^t = f_{\text{att}}(v_i, h_t), \quad v_i \in V, \quad 1 \leq t \leq d+1 \quad (3)$$

$$\alpha_i^t = \exp(e_i^t) / \sum_j \exp(e_j^t) \quad (4)$$

$$z_t = \sum_{i=1}^n \alpha_i^t v_i \quad (5)$$

$$o_t = \text{GLU}([z_t; h_t]) \quad (6)$$

具体地,由一个多层感知机(MLP)实现的视觉注意力函数 $f_{\text{att}}()$ 首先被用来计算第 i 个视觉特征向量 v_i 和 h_t 之间的一个能量值 e_i^t 。每一个能量值随后在所有图像区域上进行归一化操作,从而得到一个所对应区域的权重。最后,通过将加权的图像区域特征进行相加即可得到上下文特征向量 z_t 。为计算 o_t, z_t 和 h_t 首先被拼接起来,得到的结果向量被进一步传递给一个 GLU^[19] 层,其中, $[\cdot]$ 表示在特征维度上的拼接操作。需要注意的是,初始的隐藏层状态 h_0 、初始的记忆单元状态 m_0 和初始的输出层上下文特征向量 o_0 均被初始化为一个零向量。在时刻 t , 输出词语所对应的概率分布由 o_t 确定,如式(8)所示。

$$p(y_t | y_{0:t-1}, V) \propto \exp(E_0 o_t) \quad (7)$$

其中, $E_0 \in \mathbb{R}^{K \times d_m}$, d_m 表示解码器记忆单元的数目。模型优化算法首先通过最小化交叉熵损失函数来学习图像描述生成模型,如式(8)所示。

$$L_{\text{XENT}} = - \sum_{t=1}^{d+1} p(y_t | y_{0:t-1}, V, \theta) \quad d \geq 1 \quad (8)$$

其中, θ 表示模型参数。随后,优化算法使用强化学习损失函数 $L_{\text{RL}} \approx -r(\tilde{Y})$ 来进一步优化图像描述生成模型,其中 $\tilde{Y}$ 表示从模型采样得到的句子。此外,Self-Critical 方法^[3]被用来减小奖励估计的方差,如式(8)所示。

$$\nabla_{\theta} L_{\text{RL}} \approx - (r(\tilde{Y}) - r(\hat{Y})) \cdot \nabla_{\theta} \log p_{\theta}(\tilde{Y}) \quad (9)$$

其中, $\hat{Y}$ 表示模型通过贪婪解码方式生成的句子。

2.3 正负语义关系三元组的生成

本文方法的目标是通过对图像多模态嵌入的空间结构进行塑形来提升基于序列学习的图像描述生成模型性能。考虑到一个图像文本描述包含有很多词语,并且这些词语在语义和句法上扮演着不同的角色,本文方法首先需要确定上述的空间结构塑形需要作用于哪些词语所对应的嵌入上。因为图像描述生成任务关注图像中的显著性物体及其交互关系,所以本文方法关注基于关系的多模态嵌入塑形,即只对那些构成一个关系的词语所对应的多模态嵌入进行塑形。一个关系可表示成一个三元组 (s, a, o) , 如 (“dog”, “running on”, “grass”), 其中主语(s)和宾语(o)各自仅包含一个词语,而动作(a)可能会包含多个词语。目前的文本解析算法^[20]可在人工标注的训练句子中自动化识别出上述这类关系三元组,这样的关系被看作是图像的正(Positive)关系。因为本文方法使用三元组损失函数^[5, 10]来实现对嵌入的塑形,则在模型的训练阶段需为每一个正关系随机构造一个负(Negative)关系。算法 1 展示在模型训练阶段如何为一幅训练图像生成一批正负关系三元组对(Pair)。值得注意的是,在算法 1 中主语实体(Entity)集合与宾语实体集合并未被合并成一个实体集合,因为在一个关系三元组中的词语是有序的(Ordered)。为描述方便,在下文中基于一幅图像来介绍相关方法。

2.4 语义嵌入三元组的组成

基于算法 1,本文方法可为一幅训练图像生成一批关系三元组对,其中每一对包含一个正关系三元组和一个负关系三元组。对于句子 $Y = (y_0, \dots, y_d, y_{d+1})$, 其中的一个正关系三元组 (s, a, o) 可表示为 $(y_{i_0}, y_{i_1}, \dots, y_{i_k}, y_{i_{k+1}})$, y_{i_0} 是主语, $\langle y_{i_1}, \dots, y_{i_k} \rangle$ 是动词, $y_{i_{k+1}}$ 是宾语, $k \geq 1, 0 < i_0 < i_1 < \dots < i_k < i_{k+1} < d+1$ 。此外,上述正关系三元组所对应的负关系三元组 (s', a, o') 可表示为 $(y_{i_0}^n, y_{i_1}, \dots, y_{i_k}, y_{i_{k+1}}^n)$ 。其中,由算法 1 可知,条件 $s' \neq s$ 和 $o' \neq o$ 有且只有一个成立。根据式(1),本文方法可将上述三元组中的词语替换成相应的语义嵌入,正嵌入三元组和负嵌入三元组可分别表示为 $(x_{i_0}, x_{i_1}, \dots, x_{i_k}, x_{i_{k+1}})$ 和 $(x_{i_0}^n, x_{i_1}, \dots, x_{i_k}, x_{i_{k+1}}^n)$ 。同时,本文将从训练集中提取的三元组看作常识,且认为这些

常识都是对的。本文通过检查所构造的负例是否出现在训练集中来决定所构造的负例是否被采用,即所构造的负例不在训练集中,本文认为负例违反常识,用负例来计算三元组损失。

在上面的正负嵌入三元组中,因为动词所对应的词嵌入个数不确定,则需对上述正负嵌入三元组做进一步的转换以确保每一个目标三元组仅包含三个嵌入,从而能将目标三元组用于三元组损失函数项的计算。具体地,本文方法通过将动词所对应的嵌入进行相加来获得最终的动词嵌入表示,即 $x^{1:k} = \sum_{j=1}^k x_{i_j}$ 。通过这种方式可得到新的正负语义嵌入三元组,即 $(x_{i_0}, x^{1:k}, x_{i_{k+1}})$ 和 $(x_{i_0}^n, x^{1:k}, x_{i_{k+1}}^n)$ 。如图 1 所示, (people, in, stone) 是根据上述算法构造的负关系三元组例子。

值得注意的是,在本文方法中图像描述生成模型需进行两个阶段的学习,即基于交叉熵损失函数的学习和基于强化学习损失函数的学习。然而,在最后一阶段,人工标注的训练句子将不会直接作为模型学习的监督信息。此外,从模型中采样得到的句子通常包含错误并从这些句子中动态提取关系三元组非常耗时。因此,在基于强化学习损失函数的学习阶段,本文方法要求模型仍基于从人工标注句子中提取的关系三元组来进行多模态嵌入塑形,即本文方法将多模态嵌入三元组的空间约束关系当作常识且这些常识并不会因为使用不同的损失函数而发生变化。

2.5 视觉嵌入三元组的组成

在基于序列学习的图像描述生成中,模型在每个时刻根据式(5)去计算得到的自适应视觉上下文嵌入对于获取好的生成结果非常重要。同时,这样的视觉上下文嵌入与其相应的词语具有对齐关系。例如,当要生成词语“dog”时,模型的注意力模块将会给“dog”所对应的图像区域分配高权重,以此来得到一个以“dog”视觉特征为主的视觉上下文嵌入。然而,由于模型的记忆遗忘和错误累积问题,通过模型隐藏层状态计算得到的这样一个视觉上下文嵌入可能并不够准确。因此,为学习更好的视觉上下文嵌入,本文通过对视觉上下文嵌入施加空间上的约束来迫使模型去更好地关注一幅图像的显著性区域。

与语义嵌入塑形相同,本文方法只关注一个关系中的词语所对应的视觉嵌入。当图像描述生成模

型基于交叉熵损失函数进行学习时,与一个关系中词语对齐的视觉上下文嵌入将会被选择来构成一个正的视觉嵌入三元组。形式化地,基于公式(5),与句子 Y 对应的视觉嵌入序列可表示为 $\mathbf{Z}=(\mathbf{z}_1, \dots, \mathbf{z}_{d+1})$ 。对于一个正关系三元组 $(y_{i_0}, y_{i_1}, \dots, y_{i_k}, y_{i_{k+1}})$,其对应的视觉嵌入三元组可表示为 $(\mathbf{z}_{i_0}, \mathbf{z}_{i_1}, \dots, \mathbf{z}_{i_k}, \mathbf{z}_{i_{k+1}})$ 。当模型基于强化学习损失函数进行学习时,本文方法将采用 Teacher-Forcing^[24]方式迫使模型去额外生成人工标注的句子 Y ,即 Y 中的词语将会被按顺序输入到模型中。通过这种方式,图像描述生成模型可生成一个类似 $\mathbf{Z}$ 的视觉嵌入序列,从而可进一步得到正视觉嵌入三元组。

对于一个正关系三元组,其相应的负关系三元组可以很容易地通过算法 1 构造。然而,如何去构造一个正视觉嵌入三元组所对应的负视觉嵌入三元组却不是很直观。本文接下来将介绍如何基于一个

正视觉嵌入三元组 $(\mathbf{z}_{i_0}, \mathbf{z}_{i_1}, \dots, \mathbf{z}_{i_k}, \mathbf{z}_{i_{k+1}})$ 和由式(3)、式(4)计算得到的注意力权重来实现上述目标。与负关系三元组的构造类似,本文方法仅对一个正视觉嵌入三元组中与主语或者宾语对应的视觉嵌入进行替换来构造负视觉嵌入三元组。为描述上的方便,假设需要替换的是主语所对应的视觉嵌入 $\mathbf{z}_{i_0}$ 。根据式(3)、式(4)可知,用于计算 $\mathbf{z}_{i_0}$ 的视觉注意力权重为 $\alpha^{i_0}=\{\alpha_i^{i_0} \mid 0 \leq \alpha_i^{i_0} \leq 1, 1 \leq i \leq n\}$ 。为迫使模型更好地去关注主语所对应的显著性图像区域,本文方法通过更多地去关注这些显著性区域之外其他区域的方式来构造负视觉嵌入样本。具体地,本文方法首先计算与 α^{i_0} 互补的权重,即 $\alpha^{c,i_0}=\{\alpha_i^{c,i_0}=1-\alpha_i^{i_0} \mid 1 \leq i \leq n\}$ 。基于 α^{c,i_0} 可计算 $\mathbf{z}_{i_0}$ 对应的负视觉嵌入,如式(10)所示。

$$\mathbf{z}_{i_0}^n = \sum_{i=1}^n (\alpha_i^{c,i_0} / \sum_{j=1}^n \alpha_j^{c,i_0}) \mathbf{v}_i \quad (10)$$

算法 1 训练图像正负关系三元组对集合的生成

输入: 从所有训练图像的标注句子中提取的关系三元组 $T=\{(s,a,o), \dots\}$,由 T 中所有三元组的主语构成的实体集合 E_s ,由 T 中所有三元组的宾语构成的实体集合 E_o ,二值随机数生成器 g 。

输出: 一个包含正负关系三元组对的集合。

```

1:  $T_i \leftarrow$  获取第  $i$  幅训练图像的所有三元组;  $\{T_{\text{batch}}\} \leftarrow \emptyset$ ; //初始化为一个空集合
2: for  $r=(s,a,o) \in T_i$  do
3:   while true do
4:      $b \leftarrow g(\cdot)$ ; //从  $\{0,1\}$  中随机获取一个数值
5:     if  $b=1$  do
6:        $s' \leftarrow \text{sample}(E_s)$ ; //通过采样得到一个主语实体
7:        $r'=(s',a,o)$ ; //构建一个负三元组
8:     else do
9:        $o' \leftarrow \text{sample}(E_o)$ ; //通过采样得到一个宾语实体
10:       $r'=(s,a,o')$ ; //构建一个负三元组
11:     if  $r' \notin T$  do
12:        $T_{\text{batch}} \leftarrow T_{\text{batch}} \cup \{(r,r')\}$ ;
13:     break; //结束 while 循环
14: return  $T_{\text{batch}}$ 。
```

通过上述方式,负视觉嵌入三元组可表示为 $(\mathbf{z}_{i_0}^n, \mathbf{z}_{i_1}, \dots, \mathbf{z}_{i_k}, \mathbf{z}_{i_{k+1}}^n)$,其中 $\mathbf{z}_{i_0}^n \neq \mathbf{z}_{i_0}, \mathbf{z}_{i_{k+1}}^n = \mathbf{z}_{i_{k+1}}$ 。与语义嵌入三元组类似,与动作词语对应的视觉嵌入将被相加来得到一个视觉嵌入,即 $\mathbf{z}^{1:k} = \sum_{j=1}^k \mathbf{z}_{i_j}$ 。最终,新的正视觉嵌入三元组和负视觉嵌入三元组可分别表示为 $(\mathbf{z}_{i_0}, \mathbf{z}^{1:k}, \mathbf{z}_{i_{k+1}})$ 和 $(\mathbf{z}_{i_0}^n, \mathbf{z}^{1:k}, \mathbf{z}_{i_{k+1}}^n)$ 。

2.6 多模态嵌入塑形与图像描述生成的结合

基于上面得到的正负多模态嵌入三元组,本文方法即可计算用于多模态嵌入塑形的三元组损失函数项。在进行具体的塑形之前,所有的嵌入将首先被投影到一个维度为 d_p 的新向量空间中,空间约束

随即可施加到经过投影得到的多模态嵌入上。为描述上的方便, s 和 o 被用来分别表示一个正嵌入三元组中的主语和宾语所对应的嵌入。类似地, s^n 和 o^n 被用来分别表示一个负嵌入三元组中的主语和宾语所对应的嵌入。因为正负嵌入三元组共享相同的动作,则 a 被用来表示动作所对应的嵌入。值得注意的是,上述符号适用于语义或视觉嵌入三元组。最后,三元组损失项的计算如式(11)所示。

$$L_{\text{reg}} = \frac{1}{|T_{\text{batch}}|} \sum_{(r,r') \in T_{\text{batch}}} [\gamma + \rho(\|\mathbf{W}_s s\| + \|\mathbf{W}_a a\|, \|\mathbf{W}_o o\|) - \rho(\|\mathbf{W}_s s^n\| + \|\mathbf{W}_a a\|, \|\mathbf{W}_o o^n\|)]_+ \quad \gamma > 0 \quad (11)$$

其中, $\mathbf{W}_s \in \mathbb{R}^{d_p \times d_s}$, $\mathbf{W}_a \in \mathbb{R}^{d_p \times d_s}$, $\mathbf{W}_o \in \mathbb{R}^{d_p \times d_s}$, $* \in \{s, v\}$, $\|\cdot\|$ 表示将一个向量转换成单位向量的操作, ρ 表示距离函数, γ 是一个间隔 (margin) 常数, $[x]_+$ 表示 x 的非负部分。本文方法采用两种距离函数, 即 L_1 距离和 L_2 距离。在下文中, L_{reg}^s 和 L_{reg}^v 被用来分别表示语义和视觉嵌入三元组所对应的损失函数项。基于三元组损失函数项, 图像描述生成模型通过多任务学习的方式与多模态嵌入塑形任务进行结合, 如式(12)所示。

$$L_{\text{mt}} = L_* + \lambda L_{\text{reg}}^m, \quad * \in \{XENT, RL\}, \quad m \in \{s, v\} \quad (12)$$

其中, λ 是一个取值大于零的权重因子。

3 实验和分析

本节将通过实验来验证所提出关系驱动图像多模态嵌入塑形方法的有效性。

3.1 数据集和预处理

本文将在 Flickr30k 和 MSCOCO 这两个数据集上验证所提出方法的有效性。Flickr30k 中训练集有 29 000 幅图像, 验证集有 1 014 幅图像, 测试集有 1 000 幅图像。MSCOCO 中训练集有 113 287 幅图像, 验证集有 5 000 幅图像, 测试集有 5 000 幅

图像。在两个数据集中, 每一幅图像都对应至少 5 个人工标注的句子。值得注意的是, MSCOCO 有在线 (Online) 和离线 (Offline) 两种划分, 其中在线测试集仅包含图像而相应的人工标注句子并未公布。为便于进行离线测试和比较, Karpathy 等^[21] 从在线验证集中选取 10 000 幅图像来构建离线的验证集和测试集, 这两个集合各自包含 5 000 幅图像。在线验证集中剩余的图像一般被当作训练图像来使用。在数据预处理方面, 本文只保留在训练集和验证集中出现频率大于 5 的词语, 从而为 Flickr30k 和 MSCOCO 构建大小分别为 6 898 和 9 326 的词表。为减少模型训练的时间开销, 本文分别使用大小为 22 和 16 的长度阈值来对 Flickr30k 和 MSCOCO 的人工标注训练句子进行裁剪。此外, 本文利用 Yang 等^[22] 提供的句子场景图生成工具来提取人工标注句子中的关系三元组。但是, 上述工具会对词语进行词干提取和词形还原等处理。因此, 本文需要将这些关系三元组中的词语还原成人工标注句子中的原始词语。经过该后期处理, 本文在 Flickr30k 和 MSCOCO 上分别得到 297 735 和 989 384 个有效的关系三元组。同时, 本文并未将无法还原的关系三元组用于模型训练。图 2 展示一幅 MSCOCO 训练集图像所对应的人工标注句子和所提取的关系三元组。

图像	人工标注的句子	关系三元组
	(1) little girl looking down at leaves with her bicycle with training wheels parked next to her. (2) a little girl in a red jumpsuit and sweater is near a red bike and red table. (3) a young child in a park next to a red bench and red bicycle that as training wheels. (4) a little girl standing next to a red bike near leaves. (5) small child next to a picnic table and tricycle.	girl looking down with bicycle / girl looking down with wheels / girl in sweater / girl near bike / girl in jumpsuit / park next to bench / park next to bicycle / child in park / park next to wheels / child in park / girl standing to bike / bike near leaves / child next to table / child next to tricycle

图 2 图像关系三元组样例

3.2 模型参数设置

本文采用文献[23]提取的 Bottom-Up 区域视觉特征作为图像的视觉特征表示, 其中以 ResNet-101^[24] 模型作为骨干网络的 Faster-RCNN 物体检测模型被用作图像的编码器。每一幅图像具有自适应数量的检测区域, 范围为 10~100。此外, LSTM 解码器记忆单元的个数和词嵌入的维度均被设置为 1 024。“图像-句子”对训练样本所对应的批大小被

设置为 160。对于某一批训练样本, 本文将该批内每个训练样本所对应的全部关系三元组都用来计算相应的多模态嵌入塑形损失项。Adam^[25] 被用作模型训练的优化器。验证集上的 CIDEr 值被用于模型选择。每个模型首先使用交叉熵损失函数进行 30 个周期的预训练, 且初始学习率为 2×10^{-4} 。在验证集上取得最好 CIDEr 值的模型被选择出来, 并使用强化学习 (RL) 损失函数做进一步精调。在该阶段, 初始学习率为 2×10^{-5} , 且学习率对应的衰减

率为 0.9。Dropout^[26]和早停(Early Stopping)策略被用来实现对模型的正则化。在推理阶段,模型使用集束搜索(Beam Search)算法来生成句子且集束大小被设置为 3。式(12)中的权重因子 λ 的取值被设置为 1。

3.3 评价指标

本文使用 BLEU@n($B@n$)($n=1, 2, 3, 4$)、METEOR (M)、ROUGE_L (R)、CIDEr (C)和 SPICE (S)作为评价指标。此外,本文关注每个模型相对于基线模型的性能增益,则引入一个新的指标(即 G 指标)来评价本文所提出模型的性能,该指标被定义为提出的模型相对于基线模型在所有指标上的性能增益之和。一个模型的 G 指标值越高,则该模型的性能就越好。在一个表格中,当有不同模型需要进行比较时,最优的 G 值将被标注为粗体。需要注意的是,为简便,本文在一些表格中仅为 $B@n$ 指标报告在 $n=4$ 情况下的分数,即 $B@4$ 分数。在验证集上,一个模型在全部指标上所对应分数的和被作为该模型所使用超参数取值的评价分数。一个超参数取值的评价分数越高,则该超参数的取值就越优。此外,为节约空间,本文只报告基于 RL 损失函数的实验结果。

3.4 定量评价

在实验中,为验证所提出关系驱动图像多模态嵌入塑形方法有效性,本文定义一个基线模型(即 Baseline),在训练时未使用多模态嵌入塑形损失函数项。在每个数据集上,本文首先训练 3 个独立的基线模型,随后从这些模型中选择在验证集上取得最优 CIDEr 指标值的模型作为最终的基线模型,并将该模型用于和基于嵌入塑形的模型进行比较。多模态嵌入塑形的关键点是确定如式(11)所示的三元组损失函数中各个超参数的具体取值,即经投影得到的向量维度 d_p 和间隔常数 γ 。由于超参数的取值范围无限大且序列模型的训练比较耗时,本文无法探索所有可能的超参数取值组合。通过借鉴相关工作的实验设置^[5-8],本文在实验中基于经验将 d_p 的取值限制在 $\{100, 200, 300\}$,同时将 γ 的取值限制在 $\{1, 2, 3, 4, 5\}$ 。此外,使用 L_1 和 L_2 距离函数

来计算两个向量之间的距离,并将这两个函数分别表示为“ $L1N$ ”和“ $L2N$ ”。每个超参数的最终取值将根据在验证集上取得最优评价分数的模型来确定。对于使用语义嵌入塑形的模型,其名字以“ S ”开头,而对于使用视觉嵌入塑形的模型,其名字以“ V ”开头。同时,这些符号后面紧跟着所使用距离函数的名称,如“ S_L2N ”。

在 Flickr30k 和 MSCOCO 测试集上的实验结果如表 1 所示,可以观察到六个方面。第一,除在 Flickr30k 上的 V_L2N 模型,其他模型均取得正的 G 值,这说明通过构建一个关系中不同词语所对应的语义或视觉嵌入之间紧密的空间依赖关系,本文所提出关系驱动的图像多模态嵌入塑形方法能帮助基于序列学习的图像描述生成模型学习到更好的多模态嵌入。第二,如表 1 所示,在 Flickr30k 上的基线模型绝对性能比在 MSCOCO 上的基线模型绝对性能要差。这说明在 Flickr30k 上模型更难去学习到准确的图像多模态嵌入。从表 1 中的实验结果可看出,本文的语义或视觉嵌入塑形方法在 Flickr30k 上的表现比在 MSCOCO 上要好,即由于序列模型上述内在问题的影响,Flickr30k 上的模型性能对图像多模态嵌入的准确性更加敏感。第三,对于语义嵌入塑形, L_2 距离在两个数据集上均比 L_1 距离表现得更好。不同的是,对于视觉嵌入塑形, L_1 距离比 L_2 距离表现更好。这说明语义和视觉模态数据的嵌入空间具有一定差异。第四,在 MSCOCO 上,语义嵌入塑形比视觉嵌入塑形表现得更好,但在 Flickr30k 上情况正好相反。其中可能的原因是,这两个数据集语义或视觉模态数据的嵌入空间存在差异,同时本文所使用的超参数取值设置对于不同模态的数据而言并非最优。第五,在 Flickr30k 上, V_L1N 和 V_L2N 所对应 G 值的差异非常大。这说明 Flickr30k 上视觉嵌入塑形对距离函数的选择非常敏感,同时也反映不同词语的视觉嵌入之间确实存在某种特定的空间结构关系。第六,在 Flickr30k 上, V_L2N 在验证集上能够取得比基线模型更好的结果,但该模型在测试集上的 G 值为负。这可能是由 Flickr30k 中验证集和测试集的数据分布差异比较大造成,因为这两个数据划分所包含的图像数量都比较少。

表 1 多模态嵌入塑形的实验结果


数据集	模型	d_p	γ	B@4	M	R	C	S	G
Flickr30k	Baseline	—	—	30.73	23.18	51.29	68.47	17.32	—
	S_L1N	200	3	31.03	23.37	51.63	69.73	17.50	+2.27
	S_L2N	200	4	31.24	23.43	51.81	70.09	17.60	+3.18
	V_L1N	300	3	31.53	23.65	51.94 *	70.83 *	17.76 *	+4.72
	V_L2N	200	4	30.67	23.07	51.43	67.87	17.39	-0.56
MSCOCO	Baseline	—	—	37.78	28.60	58.53	123.61	22.25	—
	S_L1N	200	5	38.24	28.69	58.53	124.42	22.43 *	+1.54
	S_L2N	200	1	38.20	28.79 *	58.76 *	124.67 *	22.33	+1.98
	V_L1N	200	3	38.59 *	28.67	58.61	124.48	22.22	+1.80
	V_L2N	300	5	38.32	28.58	58.70	123.65	22.26	+0.74

注：* 表示在测试集上通过 p-value 为 5% 显著性检验的指标。加粗但未标记 * 表示通过显著水平小于 8% 的显著性检验。


整体上,表 1 中的实验结果验证本文所提出的关系驱动图像多模态嵌入塑形方法有效性。由于式(11)中的超参数 d_p 和 γ 的取值空间巨大,本文只能对其中非常有限的一个空间进行探索,是否存在更优的超参数取值设置且这两个超参数取值之间的关系仍需进一步探索。

3.5 定性评价

本节通过可视化方式来直观展示多模态嵌入塑形对图像描述生成模型所学习到的多模态嵌入产生的影响。如图 3 所示,本文使用 t -SNE^[27] 对 MSCOCO 上的基线模型和 S_L1N 模型所学习到



(a) Baseline学习的词嵌入



(b) V_L1N生成的视觉注意力映射

图 3 图像描述生成模型在 MSCOCO 上所学习到词嵌入的可视化

的原始词嵌入进行可视化,其中这些词嵌入对应关系三元组中出现频率最高的前 300 个词语。同时,名词、动词和介词被分别标记为红色、蓝色和橙色。可观察到,名词所对应的词嵌入倾向于构成一个簇,而动词和介词所对应的词嵌入则倾向于构成另外一个簇。虽然动词和介词具有不同的词性标签,但这两类词语都起到联系一个关系中主语和宾语的作用。因此,图像描述生成模型并未存在将这两类词语划分成不同簇的倾向。此外,与图 3(a)中的词嵌入划分情况相比,图 3(b)中名词所对应的词嵌入与动词和介词所对应的词嵌入可被更好地划分开来。在这个意义上,本文的语义嵌入塑形方法被证明可有助于图像描述生成模型学习到空间结构更好的词嵌入。

在图 4 中,本文对 MSCOCO 上基线模型和 V_L1N 模型为一幅训练图像生成对应人工标注句子时所得到的视觉注意力映射序列进行可视化,其中图像的人工标注句子所包含的关系三元组“kid holding to sign”涉及两个显著性物体,即小男孩和停车牌。可观察到,在生成词语“kid”和“sign”时,V_L1N 模型能更好地关注到对应的显著性物体。同时,从整个句子的角度来看,V_L1N 模型所生成的视觉注意力映射序列更加合理,这证明本文所提出的视觉嵌入塑形方法的有效性,即本文的视觉嵌入塑形方法能让图像描述生成模型更好地关注图像的显著性区域。




图 4 MSCOCO 训练图像所对应视觉注意力映射序列的可视化

在图 5 中,本文在 MSCOCO 的测试集上进行对比实验,分别利用没有三元组损失监督的基线模

型和本文模型生成图像描述,即给出三元组、Ground Truth (GT)、本文模型生成的结果,以及没有对比学习损失的基线模型生成的结果。从该图可看到,在一些物体和环境具有明确交互关系的场景中,本文模型能在三元组的监督下,更好地生成物体和物体、或者物体和环境之间的关系表述。同时,也可以观察到第二张图中包含多个物体,如一个男人和一群人,基线未能预测出“man”和“others”的关系。本文推测因为 GT 描述的 others 关系位于语句靠后的位置,由于序列生成问题中的记忆遗忘等问题,基线模型没有能力生成这样的多重关系。但本文模型因为具有全局的关系嵌入约束,使得生成的关系更准确和丰富。




图 5 基于 MSCOCO 测试集的生成结果对比

3.6 与相关工作的比较

在这一节中,本文将基于多模态嵌入塑形的模型与已有相关模型进行比较,为公平起见,这里比较的对象是基于 LSTM 作为解码器的工作。这些相关模型包括:(1) HARD-ATT^[2];(2) STACK-CAP^[28];(3) UP-DOWN^[23];(4) GCN-LSTM^[10];(5) SEMANTIC-ATT^[9];(6) VISUAL-ATTR^[29];(7) SGAE^[30];(8) SELF-CRITICAL^[3]。因为目前的相关工作很少报告 Flickr30k 上的结果,所以本文主要在 MSCOCO 上进行比较。具体的比较结果如表 2 所示,其中 RL 表示强化学习损失函数,而符号“N”和“Y”分别表示模型不使用和使用 RL 损失函数来进行训练。

从表 2 可观察到,使用 Faster RCNN 编码器和 RL 损失函数的模型倾向于比其他模型取得更好的结果。在 Flickr30k 上,由于使用更优的图像视觉特征表示和损失函数,本文模型取得具有压倒性的结果。在 MSCOCO 上,GCN-LSTM 和 SGAE 这两

个模型倾向于在 CIDEr 指标上取得非常好的结果。这说明基于图神经网络^[11]的图像特征表示在提升图像描述生成模型的性能方面具有非常重要的作用。与 GCN-LSTM 和 SGAE 这两个模型相比,本文模型并未使用特别复杂和先进的模型结构,如图神经网络。然而,本文模型在除 CIDEr 之外的其他

指标上取得非常具有竞争力的结果,包括 BLEU@1、METEOR、ROUGE_L 和 SPICE。由这些指标的定义可知,本文方法在识别图像中的物体和物体之间的关系等方面具有一定优势。整体上,表 2 中的结果验证本文所提出关系驱动的图像多模态嵌入塑形方法有效性。

表 2 基于多模态嵌入塑形的模型与相关模型的对比

模型	编码器	RL	B@1	B@2	B@3	B@4	M	R	C	S
Flickr30k 测试集										
HARD-ATT ^[2]	VggNet	N	66.90	43.90	29.60	19.90	18.46	—	—	—
SEMANTIC-ATT ^[9]	GoogLeNet	N	64.70	46.00	32.40	23.00	18.90	—	—	—
V_L1N(本文模型)	Faster RCNN	Y	74.53	57.05	42.58	31.53	23.65	51.94	70.83	17.76
MSCOCO Karpathy 测试集										
HARD-ATT ^[2]	VggNet	N	71.80	50.40	35.70	25.00	23.04	—	—	—
SEMANTIC-ATT ^[9]	GoogLeNet	N	70.90	53.70	40.2	30.40	24.30	—	—	—
VISUAL-ATTR ^[29]	ResNet-101	N	73.40	56.70	43.00	32.60	25.40	54.00	100.20	18.60
STACK-CAP ^[28]		Y	78.60	62.50	47.90	36.10	27.40	—	120.40	—
SELF-CRITICAL ^[3]	Faster RCNN	Y	—	—	—	34.20	26.70	55.70	114.00	—
UP-DOWN ^[23]		Y	79.80	—	—	36.30	27.70	56.90	120.10	21.40
GCN-LSTM ^[10]		Y	80.90	—	—	38.30	28.60	58.50	128.70	22.10
SGAE ^[30]		Y	80.80	—	—	38.40	28.40	58.60	127.80	22.10
S_L2N(本文模型)		Y	81.52	65.28	50.42	38.20	28.79	58.76	124.67	22.33

3.7 讨论

本文所提出关系驱动的图像多模态嵌入塑形方法直接在嵌入层面优化图像描述生成模型的性能,其中语义嵌入塑形方法对图像描述生成模型的结构并没有具体要求。因此,该方法具有一定通用性。同时,该方法还具有一定的灵活性和可扩展性。例如,本文目前只对存在于人工标注句子中的关系三元组进行语义嵌入空间关系约束。然而,可通过词形还原、词干提取及近义词替换等操作来扩充关系集合,从而考虑词表中更多词语之间的约束关系。与语义嵌入塑形方法不同,视觉嵌入塑形方法要求图像描述生成模型必须要具有软视觉注意力模块。此外,本文的多模态嵌入塑形方法依赖于从人工标注句子中提取的关系三元组。因此,本文方法的效果会受到所提取关系三元组准确性的影响。然而,文本解析算法会犯错误,即生成一些错误的关系,如何缓解错误关系对本文方法产生的负面影响是一个

需要进一步考虑并解决的问题。整体上,本文所提出的方法简单且有效,同时为研究图像描述生成任务中多模态嵌入的空间结构提供一种比较直观的方法。

4 总结

本文针对图像描述生成,提出一种关系驱动的图像多模态嵌入塑形方法。该方法可用来约束一个关系三元组中词语所对应的图像语义或视觉嵌入之间的空间结构关系,从而更好地建模关系三元组中词语之间的多模态上下文依赖关系。定量和定性实验结果表明,本文方法能够帮助图像描述生成模型学习到更加准确的图像多模态嵌入,从而提升基于序列学习的图像描述生成性能。

参考文献

- [1] VINYALS O, TOSHEV A, BENGIO S, et al. Show and tell: A neural image caption generator [C]//

- Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 3156-3164.
- [2] XU K, BA J, KIROS R, et al. Show, attend and tell: Neural image caption generation with visual attention [C]//Proceedings of the 32nd International Conference on Machine Learning, 2015: 2048-2057.
 - [3] RENNIE S J, MARCHERET E, MROUEH Y, et al. Self-critical sequence training for image captioning [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017: 1179-1195.
 - [4] SUNDERMEYER M, SCHLUTER R, NEY H. LSTM neural networks for language modeling [C]//Proceedings of the 13th Annual Conference of the International Speech Communication Association, 2012: 194-197.
 - [5] BORDES A, USUNIER N, GARCIA-DURAN A, et al. Translating embeddings for modeling multi-relational data [C]//Proceedings of the 27th Annual Conference on Neural Information Processing Systems, 2013: 2787-2795.
 - [6] WANG Z, ZHANG J, FENG J, et al. Knowledge graph embedding by translating on hyperplanes [C]//Proceedings of the 28th AAAI Conference on Artificial Intelligence, 2014: 1112-1119.
 - [7] LIN Y, LIU Z, SUN M, et al. Learning entity and relation embeddings for knowledge graph completion [C]//Proceedings of the 29th AAAI Conference on Artificial Intelligence, 2015: 2181-2187.
 - [8] JI G, HE S, XU L, et al. Knowledge graph embedding via dynamic mapping matrix [C]//Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing of the Asian Federation of Natural Language Processing, 2015: 687-696.
 - [9] YOU Q, JIN H, WANG Z, et al. Image captioning with semantic attention [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 4651-4659.
 - [10] YAO T, PAN Y, LI Y, et al. Exploring visual relationship for image captioning [C]//Proceedings of the 15th European Conference on Computer Vision, 2018: 711-727.
 - [11] WU Z, PAN S, CHEN F, et al. A comprehensive survey on graph neural networks [J]. IEEE Transactions on Neural Networks and Learning Systems, 2021, 32(1): 4-24.
 - [12] SHI Z, ZHOU X, QIU X, et al. Improving image captioning with better use of captions [C]//Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics, 2020: 7454-7464.
 - [13] LIU D, ZHA Z J, ZHANG H, et al. Context-aware visual policy network for sequence-level image captioning [C]//Proceedings of the 26th ACM International Conference on Multimedia, 2018: 1416-1424.
 - [14] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [C]//Proceedings of the 31st Annual Conference on Neural Information Processing Systems, 2017: 5998-6008.
 - [15] HUANG L, WANG W, CHEN J, et al. Attention on attention for image captioning [C]//Proceedings of the IEEE International Conference on Computer Vision, 2019: 4633-4642.
 - [16] YU J, LI J, YU Z, et al. Multimodal transformer with multi-view visual representation for image captioning [J]. IEEE Transactions on Circuits and Systems for Video Technology, 2020, 30(12): 4467-4480.
 - [17] WEIKUM G, DONG X L, RAZNIEWSKI S, et al. Machine knowledge: Creation and curation of comprehensive knowledge bases [J]. Foundations and Trends in Databases, 2021, 10(2-4): 108-490.
 - [18] REN S, HE K, GIRSHICK R B, et al. Faster R-CNN: Towards real-time object detection with region proposal networks [C]//Proceedings of the 29th Annual Conference on Neural Information Processing Systems, 2015: 91-99.
 - [19] DAUPHIN Y N, FAN A, AULI M, et al. Language modeling with gated convolutional networks [C]//Proceedings of the 34th International Conference on Machine Learning, 2017: 933-941.
 - [20] CHEN D, MANNING C D. A fast and accurate dependency parser using neural networks [C]//Proceedings of the Conference on Empirical Methods in Natural Language Processing, 2014: 740-750.
 - [21] KARPATHY A, FEI-FEI L. Deep visual-semantic alignments for generating image descriptions [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2015: 3128-3137.
 - [22] BENGIO S, VINYALS O, JAITLY N, et al. Scheduled sampling for sequence prediction with recurrent neural networks [C]//Proceedings of the 29th Annual Conference on Neural Information Processing Systems, 2015: 1171-1179.
 - [23] ANDERSON P, HE X, BUEHLER C, et al. Bottom-up and top-down attention for image captioning and visual question answering [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2018: 6077-6086.
 - [24] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition [C]//Proceedings of

- the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 770-778.
- [25] KINGMA D P, BA J. ADAM: A method for stochastic optimization [C]//Proceedings of the 3rd International Conference on Learning Representations, 2015: 1-15.
- [26] SRIVASTAVA N, HINTON G E, KRIZHEVSKY A, et al. Dropout: A simple way to prevent neural networks from overfitting [J]. Journal of Machine Learning Research, 2014, 15(1): 1929-1958.
- [27] MAATEN L V D, HINTON G E. Visualizing data using t-sne [J]. Journal of Machine Learning Research, 2008, 9: 2579-2605.
- [28] GU J, CAI J, WANG G, et al. Stack-captioning: Coarse-to-fine learning for image captioning [C]//Proceedings of the 32nd AAAI Conference on Artificial Intelligence, 2018: 6837-6844.
- [29] YAO T, PAN Y, LI Y, et al. Boosting image captioning with attributes [C]//Proceedings of the IEEE International Conference on Computer Vision, 2017: 4904-4912.
- [30] YANG X, TANG K, ZHANG H, et al. Auto-encoding scene graphs for image captioning [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2019: 10677-10686.
- [31] WANG L, LI Y, LAZEBNIK S. Learning deep structure-preserving image-text embeddings [C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016: 5005-5013.



周练(1989—), 博士, 主要研究领域为多模态/跨模态学习、图像描述生成等。

E-mail: lzhou16@fudan.edu.cn



张玥杰(1973—), 通信作者, 博士, 教授, 主要研究领域为自然语言处理、多模态/跨模态分析等。

E-mail: yjzhang@fudan.edu.cn



俞国瑞(1999—), 硕士, 主要研究领域为多模态学习、视频描述生成等。

E-mail: 21210240409@m.fudan.edu.cn